

# Registro detallado de cambios de codigo

Limpieza y reduccion de complejidad — repositorio del algoritmo genetico  
Proyecto: Genetic\_Algo\_Hull\_University | Autor: Alvaro Rivera-Eraso (MSc, University of Hull)  
Estado: preparado para verificacion en R (Codex). Cambios probados por comparacion estatica; NO ejecutados en R.

## 0. Como leer este documento

Este informe detalla, archivo por archivo, cada cambio aplicado al codigo R del proyecto a lo largo del proceso de limpieza. Para cada tipo de cambio se muestra el codigo exacto que se elimino y el que se dejo en su lugar. El objetivo central de todo el trabajo fue: **reducir la complejidad accidental y la duplicacion del codigo sin alterar ningun resultado numerico**, de modo que el repositorio sea mas legible para un revisor (tesis y articulo) y mas facil de auditar, conservando exactamente el mismo comportamiento.

**Garantia metodologica:** cada archivo modificado se comparo contra el original ignorando comentarios, lineas en blanco y el bloque de seguimiento de modulos; en todos los casos el resto del codigo ejecutable resulto identico. La unica excepcion son los cambios deliberados documentados (eliminacion de funciones duplicadas inalcanzables y de helpers de depuracion sin uso), que se explican y justifican abajo.

**Advertencia clave:** la equivalencia se ha demostrado por analisis de texto, no por ejecucion. La verificacion definitiva (parsear, correr el pipeline y comparar el md5 de los CSV de resultados) debe hacerse en R. Es precisamente el trabajo previsto con Codex.

| Metrica                                           | Valor               |
|---------------------------------------------------|---------------------|
| Archivos .R en el repositorio                     | 52                  |
| Archivos modificados (solo forma / codigo muerto) | 27                  |
| Archivos sin cambios (ya estaban limpios)         | 25                  |
| Lineas de codigo antes                            | 29,280              |
| Lineas de codigo despues                          | 28,203              |
| Reduccion total                                   | 1,077 lineas (3.7%) |
| Contenidos unicos (de 52 archivos)                | 48                  |

# 1. Tipos de cambio aplicados (con codigo real)

## 1.1 Centralizacion del bloque de seguimiento de modulos

**Que era.** El codigo original repetia, en casi todos los modulos, un bloque de unas 22 lineas identico que redefinia el entorno `.MOD_STATUS` y las funciones `mark_module_done()` e `is_module_done()`. Su unica funcion es imprimir mensajes de progreso del tipo `[MODULE DONE]` y registrar marcas de tiempo.

**Que se pretende lograr.** Eliminar la duplicacion de ese andamiaje en cada archivo y dejar una sola fuente de verdad (el modulo 00), reduciendo ruido sin afectar el calculo.

**Verificacion de seguridad.** Se comprobo en todo el codigo que `is_module_done()` solo aparece dentro de `if (!exists("is_module_done", ...))`: jamas se usa para decidir si se ejecuta un calculo. No controla el flujo numerico.

**Codigo que se ELIMINO de cada modulo (ejemplo real de 02\_scenarios\_sampling.R):**

```
if (!exists(".MOD_STATUS", inherits = TRUE) || !is.environment(.MOD_STATUS)) {
  .MOD_STATUS <- new.env(parent = emptyenv())
}
mark_module_done <- function(module_id, extra = NULL) {
  ts <- format(Sys.time(), "%Y-%m-%d %H:%M:%S")
  .MOD_STATUS[[module_id]] <- list(done = TRUE, time = ts, extra = extra)
  cat(sprintf("[MODULE DONE] %s | %s\n", ts, module_id,
    if (!is.null(extra)) paste0(" | ", extra) else ""))
  flush.console(); invisible(TRUE)
}
is_module_done <- function(module_id) {
  x <- try(.MOD_STATUS[[module_id]], silent = TRUE)
  is.list(x) && isTRUE(x$done)
}
```

**Codigo que se DEJO en su lugar (guard minimo no-operativo):**

```
# Module load tracking lives in 00_utils_debug_io.R, which is always sourced first.
# If this file is opened on its own, this tiny no-op fallback lets it run.
if (!exists("mark_module_done", mode = "function", inherits = TRUE)) {
  mark_module_done <- function(module_id, extra = NULL) invisible(TRUE)
  is_module_done <- function(module_id) FALSE
}
```

## 1.2 Eliminacion de helpers de depuracion sin uso

En cada `00_utils_debug_io.R` se eliminaron las funciones `.debug_topk_diagnose()` y `.debug_stack()`. **Que se pretende lograr:** quitar utilidades de diagnostico huerfanas. **Verificacion:** se confirmo por busqueda en todos los archivos de cada fase que ninguna se invoca en ningun sitio.

## 1.3 Refactor real: funciones duplicadas en 08\_LocationEstimators.R

**Que era.** Se detectaron 8 funciones **definidas dos veces** en el mismo archivo. En R la segunda definicion sobrescribe a la primera antes de que el archivo se use; se verifico que la primera copia **nunca se invoca** entre ambas definiciones, por lo que es codigo muerto inalcanzable. Las funciones (con sus lineas en el original de la fase 1) son:

| Funcion                                           | 1a copia (muerta) | 2a copia (vigente) |
|---------------------------------------------------|-------------------|--------------------|
| <code>.regime_rate_bin</code>                     | L182              | L478               |
| <code>.regime_scale_bin</code>                    | L191              | L493               |
| <code>.regime_sample_size_bin</code>              | L199              | L526               |
| <code>.add_regime_columns</code>                  | L206              | L573               |
| <code>.allowed_benchmarks_for_distribution</code> | L228              | L622               |
| <code>.summarize_one_regime</code>                | L240              | L647               |
| <code>build_regime_discovery_summary</code>       | L347              | L809               |

|                                        |      |      |
|----------------------------------------|------|------|
| select_regimes_for_specialist_training | L378 | L833 |
|----------------------------------------|------|------|

**Que se pretende lograr:** eliminar 273 lineas de codigo muerto por archivo y dejar cada funcion definida una sola vez, lo que evita la ambigüedad de tener dos versiones de la misma funcion. **Verificacion:** tras el borrado, las funciones activas quedan identicas y cada una se define una sola vez. Aplicado en fase 1 (3664 a 3374) y fase 3 (4162 a 3873). Test incluido: TEST\_08\_equivalencia.R.

## 1.4 Comentarios

Se tradujeron algunos comentarios de espanol/spanglish a ingles y se aclararon variables opacas. Ningun comentario afecta la ejecucion. La logica permanece intacta.

## 2. Hallazgo que requiere decision en R (NO modificado)

En 05\_ga\_core.R de la fase 3 (validation, N\_EST=26), la funcion summarize\_scenario esta definida **dos veces**, pero a diferencia del caso del modulo 08, aqui **ambas versiones se usan**:

- Copia 1 (linea 157, 157 lineas): identica a la version de la fase 1. La emplea la llamada interna de la linea 1165.
- Copia 2 (linea 1558, 49 lineas): version mas corta y distinta. Sobrescribe a la copia 1 al cargarse el modulo; la llamada desde 07\_fitness\_objectives.R (linea 992) usaria esta version reducida.

Eliminar cualquiera de las dos cambiaria el comportamiento segun el orden de carga. Por eso se dejo **sin modificar**. **Accion recomendada en R**: decidir cual de las dos versiones es la correcta, unificar y comparar resultados antes/despues. Es un posible bug latente.

## 3. Detalle por archivo

$\Delta$  = lineas eliminadas. "track" = lineas del bloque de seguimiento; "debug" = helpers de depuracion; "muerto" = código duplicado inalcanzable (modulo 08). Estado "igual" = sin cambios (ya estaba limpio).

### Fase 1 - Discovery (N\_EST=10)

| Archivo                         | Antes | Desp. | $\Delta$ | Que se quito                               |
|---------------------------------|-------|-------|----------|--------------------------------------------|
| 00_utils_debug_io.R             | 443   | 395   | 48       | 2 debug, 47 otros                          |
| 01_paths_repro.R                | 176   | 153   | 23       | 11 track, 17 otros                         |
| 02_scenarios_sampling.R         | 356   | 341   | 15       | 9 track, 11 otros                          |
| 03_distributions_params.R       | 287   | 272   | 15       | 9 track, 11 otros                          |
| 04_estimators_registry.R        | 322   | 299   | 23       | 12 track, 17 otros                         |
| 05_ga_core.R                    | 1482  | 1463  | 19       | 10 track, 20 otros                         |
| 06_data_prep.R                  | 418   | 403   | 15       | 9 track, 11 otros                          |
| 07_fitness_objectives.R         | 1266  | 1247  | 19       | 10 track, 16 otros                         |
| 08_LocationEstimators.R         | 3664  | 3374  | 290      | ~273 muerto (8 funcs duplicadas), 10 track |
| 10_distributional_diagnostics.R | 527   | 521   | 6        | 6 track, 5 otros                           |
| 11_validation_suite.R           | 1534  | 1522  | 12       | 10 track, 7 otros                          |
| run_experiment.R                | 128   | 128   | 0        | sin cambios                                |

### Fase 2 - Fixed-weight (N\_EST=10)

| Archivo                          | Antes | Desp. | $\Delta$ | Que se quito |
|----------------------------------|-------|-------|----------|--------------|
| 00_validation_helpers.R          | 101   | 101   | 0        | sin cambios  |
| 01_select_regimes.R              | 85    | 85    | 0        | sin cambios  |
| 02_expanded_benchmarks.R         | 99    | 99    | 0        | sin cambios  |
| 03_fixed_weight_validation_run.R | 218   | 218   | 0        | sin cambios  |
| 04_bootstrap_ci.R                | 101   | 101   | 0        | sin cambios  |
| 05_tables_figures.R              | 40    | 40    | 0        | sin cambios  |
| 06_locked_unseen_regimes.R       | 85    | 85    | 0        | sin cambios  |
| fixed_weight_validation_config.R | 82    | 82    | 0        | sin cambios  |
| run_fixed_weight_validation.R    | 49    | 49    | 0        | sin cambios  |

### Fase 3 - Validation (N\_EST=26)

| Archivo                         | Antes | Desp. | $\Delta$ | Que se quito                                |
|---------------------------------|-------|-------|----------|---------------------------------------------|
| 00_utils_debug_io.R             | 446   | 399   | 47       | 1 track, 2 debug, 44 otros                  |
| 01_paths_repro.R                | 176   | 153   | 23       | 11 track, 17 otros                          |
| 02_scenarios_sampling.R         | 356   | 341   | 15       | 9 track, 11 otros                           |
| 03_distributions_params.R       | 287   | 272   | 15       | 9 track, 11 otros                           |
| 04_estimators_registry.R        | 393   | 376   | 17       | 12 track, 9 otros                           |
| 05_ga_core.R                    | 1606  | 1589  | 17       | 12 track, 9 otros                           |
| 06_data_prep.R                  | 421   | 404   | 17       | 12 track, 9 otros                           |
| 07_fitness_objectives.R         | 1271  | 1254  | 17       | 12 track, 9 otros                           |
| 08_LocationEstimators.R         | 4162  | 3873  | 289      | ~273 muerto (8 funcns duplicadas), 11 track |
| 10_distributional_diagnostics.R | 527   | 521   | 6        | 6 track, 5 otros                            |
| run_experiment.R                | 136   | 136   | 0        | sin cambios                                 |

### Fase 4 - Fixed-weight (N\_EST=26)

| Archivo                          | Antes | Desp. | $\Delta$ | Que se quito |
|----------------------------------|-------|-------|----------|--------------|
| 00_validation_helpers.R          | 223   | 223   | 0        | sin cambios  |
| 01_select_regimes.R              | 95    | 95    | 0        | sin cambios  |
| 02_expanded_benchmarks.R         | 99    | 99    | 0        | sin cambios  |
| 03_fixed_weight_validation_run.R | 374   | 374   | 0        | sin cambios  |
| 04_bootstrap_ci.R                | 173   | 173   | 0        | sin cambios  |
| 05_tables_figures.R              | 216   | 216   | 0        | sin cambios  |
| 06_locked_unseen_regimes.R       | 85    | 85    | 0        | sin cambios  |
| fixed_weight_validation_config.R | 93    | 93    | 0        | sin cambios  |
| random_dirichlet_gate_audit.R    | 503   | 503   | 0        | sin cambios  |
| run_fixed_weight_validation.R    | 80    | 80    | 0        | sin cambios  |

### Fase 5 - Real-world battery

| Archivo                            | Antes | Desp. | $\Delta$ | Que se quito               |
|------------------------------------|-------|-------|----------|----------------------------|
| 00_utils_debug_io.R                | 446   | 399   | 47       | 1 track, 2 debug, 44 otros |
| 02_scenarios_sampling.R            | 356   | 339   | 17       | 12 track, 9 otros          |
| 03_distributions_params.R          | 287   | 270   | 17       | 12 track, 9 otros          |
| 04_estimators_registry.R           | 393   | 376   | 17       | 12 track, 9 otros          |
| 06_data_prep.R                     | 419   | 402   | 17       | 12 track, 9 otros          |
| 11_validation_suite.R              | 1534  | 1520  | 14       | 11 track, 8 otros          |
| 13_realworld_external_battery.R    | 1699  | 1699  | 0        | sin cambios                |
| generate_external_report.R         | 280   | 280   | 0        | sin cambios                |
| realworld_external_battery_utils.R | 664   | 664   | 0        | sin cambios                |
| run_realworld_external_battery.R   | 17    | 17    | 0        | sin cambios                |

## 4. Organizacion del repositorio

Se mantuvo cada fase autocontenida: no se creo carpeta comun ni se modificaron las llamadas `source()` (decision 100% segura para la carga de modulos). Existen 4 pares de archivos identicos entre fases que se conservan a proposito como copias para que cada fase corra de forma independiente. De 52 archivos fisicos hay 48 contenidos unicos.

| Carpeta                               | Contenido                        | Archivos |
|---------------------------------------|----------------------------------|----------|
| code/1_discovery_nest10               | Discovery N_EST=10               | 12       |
| code/2_fixed_weight_validation_nest10 | Fixed-weight N_EST=10            | 9        |
| code/3_validation_nest26              | Validation N_EST=26              | 11       |
| code/4_fixed_weight_validation_nest26 | Fixed-weight N_EST=26            | 9        |
| code/5_realworld_external_battery     | Bateria real-world (40 datasets) | 10       |
| code/6_random_dirichlet_abstain_audit | Auditoria Dirichlet              | 1        |

Los 4 pares identicos conservados: 02\_scenarios\_sampling.R, 03\_distributions\_params.R y 10\_distributional\_diagnostics.R (fases 1 y 3); 02\_expanded\_benchmarks.R (fases 2 y 4).

## 5. Pasos para continuar la limpieza

### 5.1 Verificacion inmediata en R (antes de dar por buenos los cambios actuales)

- 1 **Parseo de los 52 archivos:** ejecutar `verify_clean.R`. Debe confirmar que todos parsean y que `is_module_done` no controla flujo.
- 2 **Equivalencia del modulo 08:** ejecutar `TEST_08_equivalencia.R` tras editar las rutas a los 08 originales (fase 1 y fase 3).
- 3 **Prueba numerica definitiva:** correr el pipeline completo con el codigo original y con el limpio; comparar el md5sum de un CSV de resultados clave (por ejemplo el de la bateria externa). Si coinciden, los cambios son equivalentes.

### 5.2 Resolver el caso pendiente

Decidir en R cual version de `summarize_scenario` (05\_ga\_core.R, fase 3) es la correcta, unificarla y volver a comparar resultados. Mientras no se resuelva, NO eliminar ninguna de las dos copias.

### 5.3 Siguiente nivel de limpieza (opcional, mayor esfuerzo)

Una vez confirmada la equivalencia de lo actual, los siguientes objetivos de reduccion de complejidad — que SI tocan logica y por tanto exigen test en R por cada cambio — son:

- **Modulo 08\_LocationEstimators.R:** es el mayor (mas de 3300 lineas, decenas de funciones y 24 bloques tryCatch). Revisar si hay tryCatch que silencian errores y funciones auxiliares unificables.
- **Modulo 05\_ga\_core.R:** motor del GA. Tras resolver `summarize_scenario`, evaluar simplificar funciones largas (seleccion por torneo, cruce, mutacion) sin cambiar la semilla ni la logica de seleccion.
- **Modulo 07\_fitness\_objectives.R:** revisar duplicacion de logica de evaluacion de fitness entre fases.
- **Comentarios y nombres:** homogeneizar idioma (ingles) y nombres de variables en todo el repositorio.
- **Reproducibilidad (para publicacion):** anadir un lockfile de renv, un archivo LICENSE y, si se desea DOI, archivar una version en Zenodo.

### 5.4 Metodo recomendado para cada cambio futuro

Trabajar archivo por archivo: (1) proponer el cambio, (2) generar un test en R que compare la salida antes/despues con datos e semilla fijos, (3) aceptar solo si los resultados son identicos. Nunca acumular varios refactors de logica sin ejecutar R entre uno y otro.

Documentos de soporte incluidos en el repositorio: `CLEANUP_TRACKING.md` (registro tecnico), `verify_clean.R` y `TEST_08_equivalencia.R` (scripts de verificacion en R), y este PDF.